Plan de subtareas – Observatorio de Contratación Pública (PAMD, Tercer Corte)

Nov 10, 2026 · @Jonatan

Resumen y alcance

El notebook actual cubre los cortes 1 y 2; para cerrar el Corte 3 faltan los Puntos 2, 3 y 4, completar el Punto 1 y producir los dos entregables (informe PDF y presentación). Este documento lo divide en 28 subtareas agrupadas en cinco bloques; los bloques 5 a 7 (entregables y cierre) se revisarán después.

Punto de partida. Ya existen la capa bronze en Parquet (sin particionar y particionada), la cuarentena de registros inválidos, las comparaciones de almacenamiento, `groupByKey` frente a `reduceByKey` y un PageRank entidad → contratista. Esos resultados se reutilizan; no se rehacen.

Cada subtarea tiene los mismos campos:

- **Responsable:** vacío, para que el equipo lo asigne.
- **Prioridad:** Alta si es requisito obligatorio del enunciado o bloquea otras subtareas; Media si mejora la calidad del resultado; Baja si es opcional.
- **Depende de:** subtareas que deben estar listas antes.
- **Estado:** Pendiente, En curso o Hecho (editable).
- **Descripción:** qué se hace y con qué herramienta.
- **Criterio de aceptación:** condiciones verificables para darla por terminada.
- **Evidencia:** qué se guarda para el informe y la sustentación.

Las cifras citadas del notebook (por ejemplo, 832.646 registros adjudicados) son las de sus salidas actuales y deben revisarse tras deduplicar.

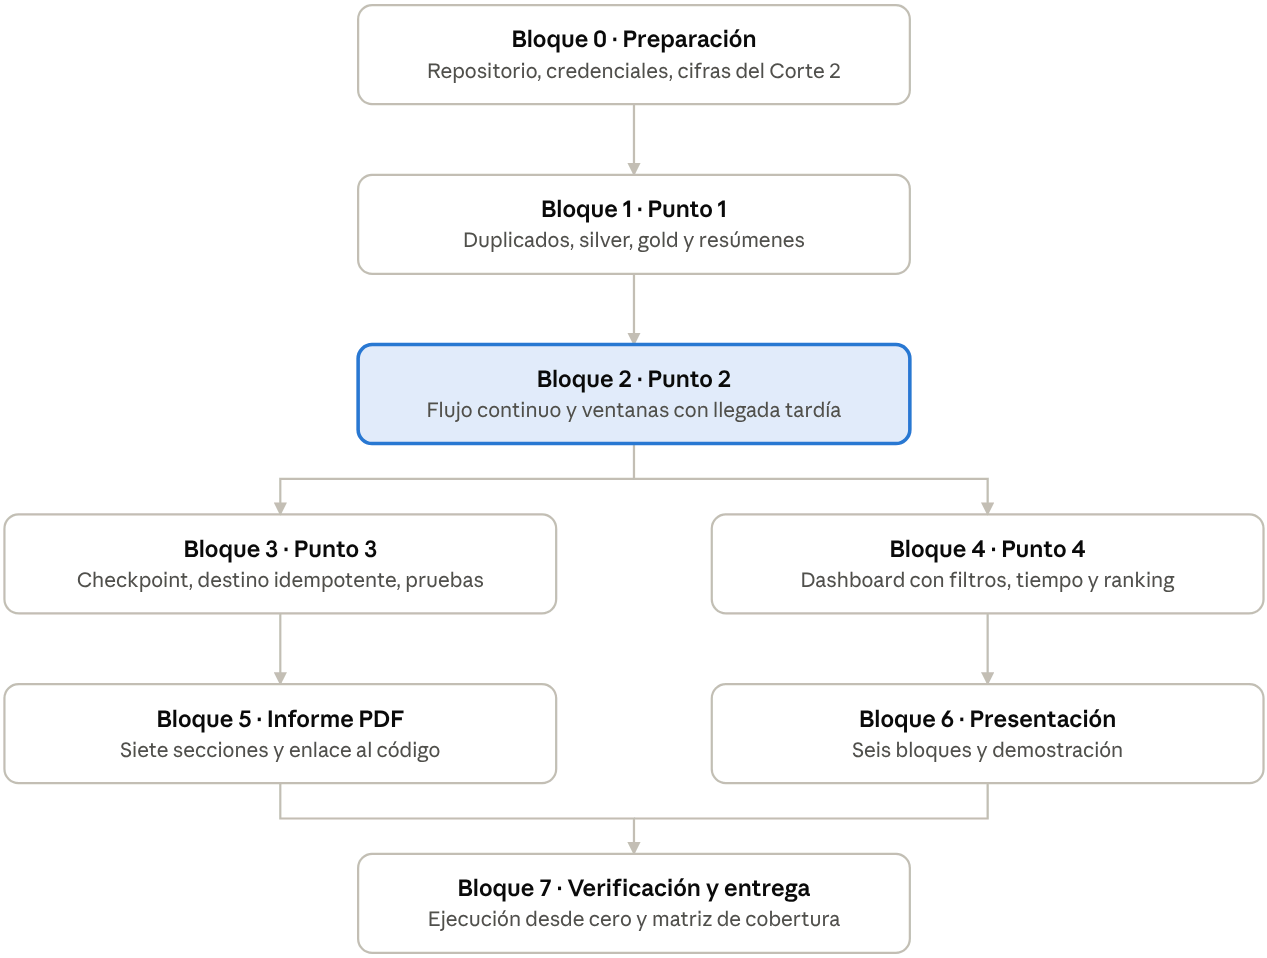
Vista general

Las 28 subtareas, por bloque, con su prioridad y dependencias. La columna Responsable queda vacía para que el equipo la complete; el detalle de cada una está en su bloque.

ID	Subtarea	Requisito	Prioridad	Depende de
T0.1	Repositorio y estructura reproducible	Preparación	Alta	–
T0.2	Sacar las credenciales del código	Preparación	Alta	T0.1
T0.3	Reconciliar cifras del Punto 2 del Corte 2	Preparación	Alta	T0.4
T0.4	Hacer ejecutables las celdas de escritura	Preparación	Alta	T0.1, T0.2
T1.1	Diagnóstico de duplicados y clave natural	Punto 1	Alta	T0.4
T1.2	Deduplicación determinista (silver)	Punto 1	Alta	T1.1
T1.3	Tabla gold de adjudicaciones	Punto 1	Alta	T1.2
T1.4	Transformaciones masivas y tablas resumen	Punto 1	Alta	T1.3
T1.5	Reconciliación y control de calidad	Punto 1	Media	T1.3
T1.6	Documentar la articulación de los cortes 1 y 2	Punto 1	Media	T1.4
T2.1	Diseño de la simulación	Punto 2	Alta	T1.3
T2.2	Generador de micro-lotes	Punto 2	Alta	T2.1
T2.3	Lectura en streaming	Punto 2	Alta	T2.2
T2.4	Agregación por ventana	Punto 2	Alta	T2.3, T2.1
T2.5	Manejo de la llegada tardía	Punto 2	Alta	T2.4
T2.6	Validación del flujo contra el cálculo por lotes	Punto 2	Alta	T2.5
T3.1	Punto de control (checkpoint) en MinIO	Punto 3	Alta	T2.3
T3.2	Destino idempotente	Punto 3	Alta	T2.4
T3.3	Deduplicación dentro del flujo	Punto 3	Alta	T3.2, T1.1
T3.4	Pruebas de fallo	Punto 3	Alta	T3.1, T3.2, T3.3
T3.5	Explicar el mecanismo	Punto 3	Media	T3.4
T4.1	Tablas de consumo del dashboard	Punto 4	Alta	T1.4, T2.4

ID	Subtarea	Requisito	Prioridad	Depende de
T4.2	Tecnología y forma de ejecución	Punto 4	Alta	–
T4.3	Filtros por región, entidad y fecha	Punto 4	Alta	T4.1, T4.2
T4.4	Visualización temporal	Punto 4	Alta	T4.3
T4.5	Ranking de los principales actores	Punto 4	Alta	T4.3
T4.6	Módulo geográfico y de concentración	Punto 4	Media	T4.3
T4.7	Pruebas de consistencia y capturas comentadas	Punto 4	Alta	T4.4, T4.5, T4.6

Tras el Punto 2, resiliencia y dashboard avanzan en paralelo



orden de ejecución · 8 bloques, 1 bifurcación

T4.2 (tecnología del dashboard) y T5.1 (esqueleto del informe) no dependen de nadie y pueden empezar desde el primer día; el resto sigue las dependencias de la tabla.

Propuesta de reparto entre dos personas

Primera propuesta: la Persona A lleva 24 puntos de dificultad (datos y streaming) y la Persona B 27 (soporte, resiliencia y dashboard). "A" y "B" son marcadores; la columna Responsable de cada subtarea sigue vacía hasta que el equipo decida quién es quién.

La dificultad es una estimación mía del esfuerzo relativo: 1 es corta, 2 media y 3 larga. No está en horas y debe ajustarse según lo que domine cada persona.

ID	Subtarea	Dificultad (1 a 3)	Persona propuesta
T0.1	Repositorio y estructura reproducible	1	B
T0.2	Sacar las credenciales del código	1	B
T0.3	Reconciliar cifras del Punto 2 del Corte 2	2	A
T0.4	Hacer ejecutables las celdas de escritura	2	A
T1.1	Diagnóstico de duplicados y clave natural	2	A
T1.2	Deduplicación determinista (silver)	2	A
T1.3	Tabla gold de adjudicaciones	2	A
T1.4	Transformaciones masivas y tablas resumen	2	B
T1.5	Reconciliación y control de calidad	1	B
T1.6	Documentar la articulación de los cortes 1 y 2	1	B
T2.1	Diseño de la simulación	1	A
T2.2	Generador de micro-lotes	2	A
T2.3	Lectura en streaming	2	A
T2.4	Agregación por ventana	3	A
T2.5	Manejo de la llegada tardía	3	A
T2.6	Validación del flujo contra el cálculo por lotes	2	A

ID	Subtarea	Dificultad (1 a 3)	Persona propuesta
T3.1	Punto de control (checkpoint) en MinIO	1	A
T3.2	Destino idempotente	3	B
T3.3	Deduplicación dentro del flujo	2	B
T3.4	Pruebas de fallo	2	B
T3.5	Explicar el mecanismo	1	B
T4.1	Tablas de consumo del dashboard	2	B
T4.2	Tecnología y forma de ejecución	1	B
T4.3	Filtros por región, entidad y fecha	2	B
T4.4	Visualización temporal	2	B
T4.5	Ranking de los principales actores	2	B
T4.6	Módulo geográfico y de concentración	2	B
T4.7	Pruebas de consistencia y capturas comentadas	2	B
	Total	**51**	**A: 24 · B: 27**

Criterio del reparto

- A lleva la cadena que no se puede paralelizar (T0.4, T1.1 a T1.3 y T2.1 a T2.6), que es también la más técnica: Spark, streaming y estado.
- B hace lo que no depende de esa cadena al inicio (T0.1, T0.2, T4.2 y un prototipo del dashboard) y, cuando A entrega gold y ventanas, sigue con los resúmenes, la resiliencia y el dashboard.
- T3.1 queda con A porque configura el checkpoint del flujo que A acaba de escribir; las pruebas de idempotencia (T3.2 a T3.4) las hace B, para tener una segunda mirada.

Bloque 0 – Preparación y deuda técnica

Antes de añadir funcionalidad hay que dejar el código reproducible y sin credenciales expuestas, porque el enunciado exige un repositorio documentado y reproducible.

T0.1 Repositorio y estructura reproducible

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	–
Estado	Pendiente
Descripción	Crear el repositorio con carpetas para notebooks, scripts, datos de ejemplo, dashboard e informe. Añadir un `README` con requisitos, cómo levantar Docker, MinIO y Spark, y en qué orden ejecutar cada notebook.
Criterio de aceptación	(1) Una persona ajena al equipo puede seguir el `README` y llegar al dashboard sin preguntar nada. (2) El repositorio incluye `docker-compose` y lista de dependencias con versiones. (3) El enlace es accesible para quien califica.
Evidencia	URL del repositorio, para incluirla en el informe.

T0.2 Sacar las credenciales del código

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T0.1
Estado	Pendiente
Descripción	Hoy las claves de MinIO están escritas en la celda de configuración de Hadoop. Leerlas de variables de entorno o de un archivo `.env`, y añadir un `.env.example` sin valores reales y el `.gitignore` correspondiente.

Campo	Detalle
Criterio de aceptación	(1) Una búsqueda de las claves en todo el repositorio, historial incluido, no devuelve resultados. (2) El notebook funciona leyendo las variables. (3) Si las claves ya se subieron algún día, se cambiaron.
Evidencia	`.env.example` y resultado de la búsqueda.

T0.3 Reconciliar las cifras inconsistentes del Punto 2 del Corte 2

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T0.4
Estado	Pendiente
Descripción	Las salidas del notebook muestran 8.118.779 registros, 11.790 entidades, 17 particiones y medianas de 7,52 s y 5,66 s. El texto de conclusiones habla de 9.040.706 registros, 11.874 entidades, 19 particiones, 11,82 s y 4,39 s. Volver a ejecutar el Punto 2 sobre la base final y reemplazar el texto por cifras generadas desde las variables, como ya hace el Punto 3.
Criterio de aceptación	(1) Ninguna cifra del texto contradice la salida de su celda. (2) El número de registros del Punto 2 coincide con el del bronze actual, o la diferencia está explicada.
Evidencia	Notebook re-ejecutado con salidas visibles.

T0.4 Hacer ejecutables las celdas de escritura

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T0.1, T0.2
Estado	Pendiente
Descripción	Las celdas que escriben el bronze y el conteo de control están comentadas porque los archivos ya existen. Reemplazar los comentarios por un parámetro (por ejemplo `RECONSTRUIR_BRONZE = False`) que las active, e indicar en el `README` cómo obtener el CSV de SECOP II.
Criterio de aceptación	En un MinIO vacío, ejecutar el notebook con el parámetro activo crea el bronze completo y los conteos cuadran: filas leídas = válidas + rechazadas.
Evidencia	Registro de una ejecución desde cero.

Bloque 1 – Punto 1: Articulación del flujo y procesamiento sin duplicidades

El enunciado pide transformaciones masivas sobre entidad, contratista, montos, fecha de adjudicación y ubicación, sin duplicados. El bronze actual no elimina duplicados ni deja una tabla centrada en adjudicaciones, así que este bloque crea esa capa.

T1.1 Diagnóstico de duplicados y elección de la clave natural

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T0.4

Campo	Detalle
Estado	Pendiente
Descripción	Medir sobre el bronze cuántas filas hay, cuántos `id_del_proceso` distintos y cuántas parejas distintas de `id_del_proceso` e `id_adjudicacion`. Revisar a mano una muestra de procesos repetidos para entender por qué se repiten (nuevas publicaciones, lotes, adjudicaciones múltiples) y elegir la clave que define "un contrato adjudicado".
Criterio de aceptación	(1) Hay una tabla con filas totales, claves distintas y filas sobrantes por cada clave candidata. (2) La clave elegida está justificada con ejemplos reales. (3) El equipo la aprobó.
Evidencia	Tabla de diagnóstico y ejemplos para el informe.

T1.2 Deduplicación determinista (capa silver)

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T1.1
Estado	Pendiente
Descripción	Quedarse con una sola fila por clave usando una función de ventana (`row_number`) con un orden explícito, por ejemplo la publicación más reciente y, en empate, un campo que desempate. Escribir el resultado como capa silver en Parquet.
Criterio de aceptación	(1) El número de filas es igual al de claves distintas, comprobado con `assert`. (2) Ejecutar dos veces da el mismo conteo y la misma suma de valores. (3) Las filas descartadas se guardan aparte con su motivo.
Evidencia	Conteos antes y después; ruta de silver en MinIO.

T1.3 Tabla gold de adjudicaciones

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T1.2
Estado	Pendiente

Campo	Detalle
Descripción	Filtrar `adjudicado = True` y fecha de adjudicación no nula. Conservar entidad (NIT, nombre, departamento, ciudad), contratista (identificador, nombre, departamento), `valor_total_adjudicacion` y `fecha_adjudicacion`, y añadir `anio_adjudicacion` y `anio_mes`. Reutilizar la regla de identificador de contratista del Punto 3 del Corte 2 (NIT, luego código, luego nombre). Escribir en Parquet particionado por año de adjudicación.
Criterio de aceptación	(1) El esquema está documentado con tipos y significado de cada columna. (2) No hay valores adjudicados negativos ni fechas anteriores a 1900 o futuras sin explicación. (3) Los registros descartados por falta de entidad o contratista están contados.
Evidencia	Esquema, conteos y ruta de gold en MinIO.

T1.4 Transformaciones masivas y tablas resumen

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T1.3
Estado	Pendiente
Descripción	Calcular con `valor_total_adjudicacion`, no con `precio_base`, los agregados por entidad, por contratista, por departamento y por mes: número de contratos, valor total y valor promedio. Guardarlos en `procesado/` como Parquet pequeño. Reaprovechar la agregación parcial del Punto 2 (equivalente a `reduceByKey`, que en DataFrames hace `groupBy().agg()`).

Campo	Detalle
Criterio de aceptación	(1) La suma de cada resumen es igual a la suma total de gold. (2) Cada tabla tiene su esquema descrito. (3) Las tablas alimentan el dashboard y las tres preguntas críticas del enunciado.
Evidencia	Rutas de las tablas y verificación de sumas.

T1.5 Reconciliación y control de calidad

Campo	Detalle
Responsable	
Prioridad	Media
Depende de	T1.3
Estado	Pendiente
Descripción	Construir una tabla de reconciliación: filas leídas, rechazadas, duplicadas, no adjudicadas, sin extremos válidos y filas finales en gold. Revisar valores atípicos (muy altos o cero) y decidir si se marcan o se dejan.
Criterio de aceptación	Las filas de cada etapa suman exactamente las de la etapa anterior; no hay filas sin explicar.
Evidencia	Tabla de reconciliación para el informe.

T1.6 Documentar cómo se articulan los cortes 1 y 2

Campo	Detalle
Responsable	
Prioridad	Media
Depende de	T1.4
Estado	Pendiente

Campo	Detalle
Descripción	Escribir qué se reutiliza de cada corte: MinIO y Parquet particionado (Corte 1), agregación parcial, sesgo de datos y PageRank (Corte 2), y qué aporta de nuevo el Corte 3. Preparar un diagrama de linaje de datos: CSV, bronze, silver, gold, resumen, dashboard.
Criterio de aceptación	Un párrafo y un diagrama que una persona externa entienda sin leer el código; cada flecha corresponde a una ruta real de MinIO.
Evidencia	Texto y diagrama para informe y presentación.

Bloque 2 – Punto 2: Flujo continuo y ventanas temporales

Hay que simular la llegada sucesiva de contratos y calcular, por ventana de tiempo, el valor total contratado y el número de procesos adjudicados, sin que un registro tardío altere el histórico. La herramienta natural es Spark Structured Streaming leyendo de una carpeta de MinIO.

T2.1 Diseño de la simulación

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T1.3
Estado	Pendiente

Campo	Detalle
Descripción	Definir en una página: de dónde sale el flujo (carpeta de micro-lotes en MinIO), cuántos lotes, cómo se ordenan (por `fecha_adjudicacion`), cada cuánto llega uno, qué porcentaje de registros tardíos se inyecta y qué se considera "tardío". Decidir también la ventana: mes calendario exacto (columna `anio_mes`) o ventana de duración fija con `window()`, que es la que admite marca de agua.
Criterio de aceptación	(1) Todos los parámetros están escritos y son configurables. (2) La decisión de ventana tiene una justificación de una línea. (3) El equipo la aprobó.
Evidencia	Página de diseño, que luego alimenta el informe.

T2.2 Generador de micro-lotes

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.1
Estado	Pendiente
Descripción	Escribir un script o celda que parta gold en N archivos y los copie, uno a uno y con una pausa, a la carpeta de entrada del flujo. Incluir uno o más lotes tardíos: contratos con fechas de adjudicación de meses ya cerrados. Usar una semilla fija para que la simulación sea repetible.
Criterio de aceptación	(1) La suma de filas de todos los lotes es igual a las filas de gold. (2) Ejecutarlo dos veces con la misma semilla genera los mismos lotes. (3) Se sabe exactamente qué lotes son tardíos.

Campo	Detalle
Evidencia	Lista de lotes con número de filas y marca de tardío.

T2.3 Lectura en streaming

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.2
Estado	Pendiente
Descripción	Crear el `readStream` con esquema explícito y `maxFilesPerTrigger`, de modo que cada disparo procese un lote. Registrar el avance de cada micro-lote (`lastProgress`).
Criterio de aceptación	La consulta se mantiene activa, procesa los lotes en orden de llegada y el número de filas de cada disparo coincide con el de su archivo.
Evidencia	Registro de progreso por micro-lote.

T2.4 Agregación por ventana

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.3, T2.1
Estado	Pendiente

Campo	Detalle
Descripción	Agrupar por ventana sobre `fecha_adjudicacion` y calcular `sum(valor_total_adjudicacion)` y número de procesos adjudicados. Producir la versión mensual y la anual, y dejar la dimensión de departamento para que el dashboard pueda filtrar por región.
Criterio de aceptación	(1) Cada ventana muestra su valor y su conteo. (2) La suma de todas las ventanas es igual al total de gold cuando el flujo termina. (3) No hay ventanas con fechas imposibles.
Evidencia	Tabla de resultados por ventana.

T2.5 Manejo de la llegada tardía

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.4
Estado	Pendiente
Descripción	Configurar la marca de agua (`withWatermark`) y el modo de salida, y decidir qué pasa con un registro que llega más tarde que la tolerancia: se descarta, se guarda en una tabla de tardíos o se reprocesa su ventana desde gold. Hacer una demostración con un lote tardío.
Criterio de aceptación	(1) Antes y después del lote tardío, solo cambia la ventana afectada; las demás quedan igual. (2) Ningún registro tardío se pierde en silencio: o se incorpora o queda registrado aparte. (3) El total acumulado final es correcto.
Evidencia	Comparación antes y después, con capturas, para el informe.

T2.6 Validación del flujo contra el cálculo por lotes

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.5
Estado	Pendiente
Descripción	Calcular las mismas agregaciones con una consulta normal sobre gold y compararlas con el resultado final del flujo, ventana por ventana.

Campo	Detalle
Criterio de aceptación	Ambos resultados son iguales en conteo y en suma para todas las ventanas (diferencia cero, o menos que el error de redondeo decimal que se haya acordado).
Evidencia	Tabla de comparación con diferencia por ventana.

Bloque 3 – Punto 3: Resiliencia y resultados idempotentes

Si el flujo se detiene o se ejecuta dos veces, las cifras finales deben ser las mismas: sin contratos duplicados y sin contratos perdidos. Eso depende de dos piezas que hay que poder explicar: el punto de control del flujo y un destino de escritura que reemplaza en vez de acumular.

T3.1 Punto de control (checkpoint) en MinIO

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.3
Estado	Pendiente
Descripción	Configurar `checkpointLocation` en una ruta de MinIO propia de este flujo. Comprobar qué se guarda allí (qué archivos ya se leyeron y el estado de las agregaciones) y documentar que cambiar la consulta puede invalidar el checkpoint.
Criterio de aceptación	Tras detener el flujo y reiniciarlo con el mismo checkpoint, no vuelve a leer los lotes ya confirmados y continúa en el siguiente.
Evidencia	Registros antes y después del reinicio.

T3.2 Destino idempotente

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T2.4
Estado	Pendiente
Descripción	Escribir el resultado con `foreachBatch` de forma que repetir un micro-lote deje el mismo estado: sobrescribir la partición de cada ventana afectada (sobrescritura dinámica de particiones) o hacer un `MERGE` por clave si se dispone de un formato de tablas transaccional. Evitar el modo `append` para los totales.
Criterio de aceptación	Procesar el mismo micro-lote una, dos o diez veces deja exactamente las mismas cifras en la tabla de destino.
Evidencia	Pruebas repetidas con conteo y suma antes y después.

T3.3 Deduplicación dentro del flujo

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T3.2, T1.1
Estado	Pendiente
Descripción	Aplicar la clave elegida en T1.1 dentro del flujo (`dropDuplicates` con marca de agua, o dedupe dentro de cada micro-lote) para que un archivo repetido en la entrada no cuente dos veces.

Campo	Detalle
Criterio de aceptación	Si se vuelve a dejar en la carpeta de entrada un lote ya procesado (o con otro nombre), las cifras no cambian.
Evidencia	Prueba de lote repetido con cifras antes y después.

T3.4 Pruebas de fallo

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T3.1, T3.2, T3.3
Estado	Pendiente
Descripción	Ejecutar tres escenarios: (A) detener el flujo a mitad y reiniciarlo; (B) ejecutar el flujo completo dos veces seguidas; (C) volver a depositar un lote ya procesado. Tras cada uno calcular el conteo total, el valor total y un resumen por ventana.
Criterio de aceptación	En los tres escenarios el resultado final es idéntico al de una ejecución limpia sin interrupciones, y es igual al cálculo por lotes de T2.6.
Evidencia	Tabla de los tres escenarios con conteo, suma y estado (igual o distinto); registros y capturas.

T3.5 Explicar el mecanismo

Campo	Detalle
Responsable	
Prioridad	Media
Depende de	T3.4

Campo	Detalle
Estado	Pendiente
Descripción	Redactar la explicación que exige el enunciado: qué guarda el checkpoint, por qué el destino reemplaza en vez de sumar, qué clave identifica un contrato y qué límites tiene el mecanismo (por ejemplo, cambios en la consulta o borrado del checkpoint).
Criterio de aceptación	Una persona externa puede responder, a partir del texto, qué pasa si el flujo se cae justo mientras escribe. El texto cabe en una página.
Evidencia	Texto para el informe y un diagrama simple para la presentación.

Bloque 4 – Punto 4: Dashboard interactivo

El dashboard debe leer las tablas resumen (no los 9 millones de filas) y permitir tres cosas: filtrar por región o entidad, ver el volumen contratado en el tiempo y ver el ranking de los principales actores. Cada módulo responde una de las tres preguntas críticas del enunciado.

T4.1 Tablas de consumo del dashboard

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T1.4, T2.4
Estado	Pendiente
Descripción	Definir y exportar, a partir de las tablas resumen, un conjunto pequeño de datos para el dashboard: serie mensual por departamento y entidad (conteo y valor), ranking de entidades, ranking de contratistas y valor por departamento. Exportar en un formato ligero (Parquet pequeño, CSV o JSON).

Campo	Detalle
Criterio de aceptación	(1) Las tablas se cargan sin Spark y en pocos segundos. (2) Cada tabla tiene el esquema documentado. (3) Sus totales coinciden con gold.
Evidencia	Lista de tablas, esquemas y tamaños.

T4.2 Tecnología y forma de ejecución

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	–
Estado	Pendiente
Descripción	Elegir la herramienta (por ejemplo Streamlit, Dash o una página web con JavaScript) según lo que el equipo domine y lo fácil que sea ejecutarla en la sustentación. Dejar escrito cómo se lanza y dónde lee los datos.
Criterio de aceptación	(1) El dashboard se abre con un solo comando o un enlace, documentado en el `README`. (2) No exige tener Spark ni MinIO en marcha para verlo. (3) La decisión quedó justificada en una línea.
Evidencia	Decisión registrada e instrucciones de arranque.

T4.3 Filtros por región, entidad y fecha

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T4.1, T4.2

Campo	Detalle
Estado	Pendiente
Descripción	Implementar filtros de departamento, entidad y rango de años o meses, aplicados a todos los gráficos a la vez. Mostrar los totales filtrados (valor y número de contratos) en tarjetas.
Criterio de aceptación	(1) Al cambiar un filtro se actualizan todos los módulos. (2) La combinación sin resultados muestra un mensaje claro, no un error. (3) Con todos los filtros abiertos, los totales son iguales a los de gold.
Evidencia	Capturas con distintas combinaciones de filtros.

T4.4 Visualización temporal

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T4.3
Estado	Pendiente
Descripción	Gráfico mensual del valor contratado y del número de adjudicaciones. Marcar los periodos de interés del enunciado: restricciones de la ley de garantías (confirmar las fechas exactas en la fuente oficial) y cierres de vigencia fiscal.
Criterio de aceptación	(1) El eje de tiempo es mensual y ordenado. (2) Los picos se pueden señalar y leer su valor. (3) Cada punto coincide con la tabla de ventanas de T2.4.
Evidencia	Captura comentada y lista de picos detectados.

T4.5 Ranking de los principales actores

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T4.3
Estado	Pendiente
Descripción	Mostrar el top N de entidades y de contratistas por valor adjudicado y por número de contratos, con N configurable y respetando los filtros. Opcional: añadir el puntaje de PageRank del Corte 2 como tercera lectura.
Criterio de aceptación	El top 10 mostrado coincide con el que devuelve una consulta Spark equivalente sobre gold, para al menos tres combinaciones de filtros.
Evidencia	Capturas y consultas de verificación.

T4.6 Módulo geográfico y de concentración

Campo	Detalle
Responsable	
Prioridad	Media
Depende de	T4.3
Estado	Pendiente
Descripción	Mostrar el valor por departamento (mapa o barras) y la participación acumulada de las entidades que concentran el gasto, para responder dónde se concentra el dinero.
Criterio de aceptación	(1) La suma por departamento es igual al total filtrado. (2) Los registros sin departamento aparecen como categoría aparte, no se ocultan.

Campo	Detalle
Evidencia	Captura y cifra de concentración citable en el informe.

T4.7 Pruebas de consistencia y capturas comentadas

Campo	Detalle
Responsable	
Prioridad	Alta
Depende de	T4.4, T4.5, T4.6
Estado	Pendiente
Descripción	Comparar al menos tres cifras del dashboard con consultas Spark independientes. Tomar una captura de cada módulo y escribir al pie qué muestra y qué permite concluir. Mostrar en pantalla la fecha del último lote procesado.
Criterio de aceptación	(1) Las cifras comparadas son iguales. (2) Hay una captura comentada por cada módulo y filtro. (3) El dashboard abre sin errores en el equipo de la sustentación.
Evidencia	Capturas comentadas (insumo directo de T5.6 y T6.2).

Bloque 5 – Entregable 1: Informe técnico (PDF)

El informe debe llamarse `Informe_Final_PAMD_Equipo.pdf` y contener siete elementos que enumera el enunciado. Se divide por sección para que cada persona escriba lo que mejor conoce, y una subtarea final lo une y revisa.

Bloque 6 – Entregable 2: Presentación ejecutiva

La presentación se llama `Presentacion_PAMD_Equipo.pptx` (o su PDF) y sigue la estructura sugerida del enunciado: portada y propósito, valor del análisis masivo, diagrama de solución, ventanas y flujo, demostración del dashboard e impacto institucional y social.

Bloque 7 – Verificación final, cobertura y riesgos

Este bloque comprueba que todo lo anterior funciona junto y que cada requisito del enunciado tiene evidencia.

Matriz de cobertura del enunciado

Requisito del enunciado	Subtareas	Cómo se comprueba
Punto 1: flujo integral sin duplicidades	T1.1 a T1.6	Reconciliación de filas (T1.5) y prueba de determinismo (T1.2)
Punto 2: flujo continuo y ventanas con llegada tardía	T2.1 a T2.6	Flujo igual al cálculo por lotes (T2.6) y demostración del lote tardío (T2.5)
Punto 3: resiliencia e idempotencia	T3.1 a T3.5	Tres escenarios de fallo con resultado idéntico (T3.4)
Punto 4: dashboard con filtros, serie temporal y ranking	T4.1 a T4.7	Cifras del dashboard iguales a consultas Spark (T4.7)
Entregable 1: informe PDF con siete secciones	T5.1 a T5.8	PDF con las siete secciones y enlace al código (T5.8)
Entregable 2: presentación ejecutiva	T6.1 a T6.4	Seis bloques y ensayo cronometrado (T6.4)
Repositorio reproducible	T0.1 a T0.4, T7.1	Ejecución desde cero (T7.1)

Riesgos

Riesgo	Efecto	Mitigación	Subtareas
La clave de un contrato no es única o los registros se repiten por motivos distintos a los supuestos	Cifras infladas o contratos perdidos	Diagnosticar primero y fijar la clave antes de construir silver y gold	T1.1
Releer el CSV es lento (en el notebook, una consulta tardó unos 840 s)	Pruebas y demostración inviables	Trabajar siempre desde bronze, silver y gold en Parquet; el CSV solo se lee al reconstruir	T0.4, T1.2
Memoria limitada (el notebook registra unos 7,6 GB en Docker)	Fallos al mantener estado del flujo	Pocas dimensiones por ventana, `maxFilesPerTrigger` bajo y lotes de tamaño moderado	T2.3, T2.4
Spark sin formato transaccional no ofrece `MERGE`	No se puede hacer upsert por clave	Sobrescribir la partición de la ventana; probar pronto si el equipo puede instalar un formato de tablas	T3.2
Ventana de mes calendario y `window()` de duración fija no son lo mismo	Ventanas que no coinciden con los meses del informe	Decidir y justificar en el diseño antes de programar	T2.1
Las fechas de la ley de garantías se citan de memoria	Marcas erróneas en el gráfico temporal	Confirmarlas en la fuente oficial antes de graficar	T4.4
El dashboard se deja para el final	Sin tiempo para capturas ni pruebas	Elegir la tecnología ya (T4.2 no depende de nadie) y maquetar con datos de gold	T4.2
Cifras distintas entre notebook, informe y presentación	Pérdida de credibilidad en la sustentación	Generar las cifras desde variables y citar siempre la misma tabla	T0.3, T7.2